

64-040 Modul IP7: Rechnerstrukturen

[http://tams.informatik.uni-hamburg.de/
lectures/2011ws/vorlesung/rs](http://tams.informatik.uni-hamburg.de/lectures/2011ws/vorlesung/rs)

Kapitel 7

Andreas Mäder



Universität Hamburg
Fakultät für Mathematik, Informatik und Naturwissenschaften
Fachbereich Informatik

Technische Aspekte Multimodaler Systeme

Wintersemester 2011/2012

Kapitel 7

Textkodierung

- Adhoc-Kodierungen
- ASCII und ISO-8859
- Unicode
- Tipps und Tricks
- base64-Kodierung
- Literatur



Darstellung von Texten


- ▶ Ad-Hoc Kodierungen
 - ▶ Flaggen-Alphabet
 - ▶ Braille-Code
 - ▶ Morse-Code
- ▶ ASCII und ISO-8859-1
- ▶ Unicode



Wiederholung: Zeichenkette

- ▶ **Zeichenkette** (engl. *string*): Eine Folge von Zeichen
- ▶ **Wort** (engl. *word*): Eine Folge von Zeichen, die in einem gegebenen Zusammenhang als Einheit bezeichnet wird. Worte mit 8 Bit werden als **Byte** bezeichnet.
- ▶ **Stelle** (engl. *position*): Die Lage/Position eines Zeichens innerhalb einer Zeichenkette.
- ▶ Beispiel
 - ▶ `s = H e l l o , w o r l d !`


Flaggen-Signale




Flaggen-Alphabet



Braille: Blindenschrift



- ▶ Symbole als 2x3 Matrix (geprägte Punkte)
- ▶ Erweiterung auf 2x4 Matrix (für Computer)
- ▶ bis zu 64 (256) mögliche Symbole
- ▶ diverse Varianten
 - ▶ ein Symbol pro Buchstabe
 - ▶ ein Symbol pro Silbe
 - ▶ Kurzschrift/Steno



Morse-Code

Punkt: kurzer Ton
Strich: langer Ton

Codetabelle des Morse-Codes					
a	• —	o	— — —	4	• • • • —
ä	• — • —	ö	— — — •	5	• • • • •
å	• — — • —	p	• — — •	6	— • • • •
b	— • • •	q	— — • —	7	— — • • •
c	— • — •	r	• — •	8	— — — • •
ch	— — — —	s	• • •	9	— — — — •
d	— • •	t	—		
e	•	u	• • —	.	• — • — • —
é	• • — • •	ü	• • — —	,	— — • • — —
f	• • — •	v	• • • —	:	— — — • • •
g	— — •	w	• — —	-	— • • • • —
h	• • • •	x	— • • —	'	• — — — — •
i	• •	y	— • — —	(— • — — • —
j	• — — —	z	— — • •	?	• • — — • •
k	— • —			“	• — • • — •
l	• — • •	0	— — — — —	Notruf	• • • — — — • • •
m	— —	1	• — — — —	SP	• •
n	— •	2	• • — — —	Anfang	— • — • —
ñ	— — • — —	3	• • • — —	Ende	• • • — • —

Morse-Code (cont.)

► Eindeutigkeit

Codewort: • • • • • – •

e → •

i → • •

n → – •

r → • – •


s → • • •

- bestimmte Morse-Sequenzen sind mehrdeutig
- Pause zwischen den Symbolen notwendig

► Codierung

- Häufigkeit der Buchstaben = $1 / \text{Länge des Codewortes}$
- Effizienz: kürzere Codeworte
- Darstellung als Codebaum

Morse-Code: Baumdarstellung (Ausschnitt)



► Anordnung der Symbole entsprechend ihrer Kodierung

ASCII

American Standard Code for Information Interchange

- ▶ eingeführt 1967, aktualisiert 1986: ANSI X3.4-1986
- ▶ viele Jahre der dominierende Code für Textdateien
- ▶ alle Zeichen einer typischen Schreibmaschine
- ▶ Erweiterung des früheren 5-bit Fernschreiber-Codes (Murray-Code)
- ▶ 7-bit pro Zeichen, 128 Zeichen insgesamt
- ▶ 95 druckbare Zeichen: Buchstaben, Ziffern, Sonderzeichen (Kodierung im Bereich 21..7E)
- ▶ 33 Steuerzeichen (engl: *control characters*) (0..1F, 7F)

ASCII: Codetabelle

Code	...0	...1	...2	...3	...4	...5	...6	...7	...8	...9	...A	...B	...C	...D	...E	...F
0...	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	HT	LF	VT	FF	CR	SO	SI
1...	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2...	SP	!	"	#	\$	%	&	'	()	*	+	,	-	.	/
3...	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4...	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5...	P	Q	R	S	T	U	V	W	X	Y	Z	[\]	^	_
6...	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7...	p	q	r	s	t	u	v	w	x	y	z	{		}	~	DEL

- ▶ SP = Leerzeichen, CR = carriage-return, LF = line-feed
- ▶ ESC = escape, DEL = delete, BEL = bell, usw.

<http://de.wikipedia.org/wiki/ASCII>

ISO-8859 Familie

- ▶ Erweiterung von ASCII um Sonderzeichen und Umlaute
- ▶ 8-bit Kodierung: bis max. 256 Zeichen darstellbar

- ▶ Latin-1: Westeuropäisch
- ▶ Latin-2: Mitteleuropäisch
- ▶ Latin-3: Südeuropäisch
- ▶ Latin-4: Baltisch
- ▶ Latin-5: Kyrillisch
- ▶ Latin-6: Arabisch
- ▶ Latin-7: Griechisch
- ▶ usw.

- ▶ immer noch nicht für mehrsprachige Dokumente geeignet

ISO-8859-1: Codetabelle (1)

Erweiterung von ASCII für westeuropäische Sprachen

Code	...0	...1	...2	...3	...4	...5	...6	...7	...8	...9	...A	...B	...C	...D	...E	...F
0...	nicht belegt															
1...																
2...	SP	!	"	#	\$	%	&	'	()	*	+	,	-	.	/
3...	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4...	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5...	P	Q	R	S	T	U	V	W	X	Y	Z	[\]	^	_
6...	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7...	p	q	r	s	t	u	v	w	x	y	z	{		}	~	
8...	nicht belegt															
9...																
A...	NBSP	ı	¢	£	¤	¥	¦	§	¨	©	ª	«	¬	SHY	®	-
B...	°	±	²	³	´	µ	¶	·	¸	¹	º	»	¼	½	¾	¿
C...	À	Á	Â	Ã	Ä	Å	Æ	Ç	È	É	Ê	Ë	Ì	Í	Î	Ï
D...	Ð	Ñ	Ò	Ó	Ô	Õ	Ö	×	Ø	Ù	Ú	Û	Ü	Ý	Þ	ß
E...	à	á	â	ã	ä	å	æ	ç	è	é	ê	ë	ì	í	î	ï
F...	ð	ñ	ò	ó	ô	õ	ö	÷	ø	ù	ú	û	ü	ý	þ	ÿ

ISO-8859-1: Codetabelle (2)

Sonderzeichen gemeinsam für alle 8859 Varianten

Code	...0	...1	...2	...3	...4	...5	...6	...7	...8	...9	...A	...B	...C	...D	...E	...F
0...	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	HT	LF	VT	FF	CR	SO	SI
1...	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2...	wie ISO/IEC 8859, Windows-125X und US-ASCII															
3...																
4...																
5...																
6...																
7...																DEL
8...	PAD	HOP	BPH	NBH	IND	NEL	SSA	ESA	HTS	HTJ	VTS	PLD	PLU	RI	SS2	SS3
9...	DCS	PU1	PU2	STS	CCH	MW	SPA	EPA	SOS	SGCI	SCI	CSI	ST	OSC	PM	APC
A...	wie ISO/IEC 8859-1 und Windows-1252															
B...																
C...																
D...																
E...																
F...																

ISO-8859-2

Erweiterung von ASCII für slawische Sprachen

Code	...0	...1	...2	...3	...4	...5	...6	...7	...8	...9	...A	...B	...C	...D	...E	...F
0...	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	HT	LF	VT	FF	CR	SO	SI
1...	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2...	SP	!	"	#	\$	%	&	'	()	*	+	,	-	.	/
3...	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4...	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5...	P	Q	R	S	T	U	V	W	X	Y	Z	[\]	^	_
6...	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7...	p	q	r	s	t	u	v	w	x	y	z	{		}	~	DEL
8...	PAD	HOP	BPH	NBH	IND	NEL	SSA	ESA	HTS	HTJ	VTS	PLD	PLU	RI	SS2	SS3
9...	DCS	PU1	PU2	STS	CCH	MW	SPA	EPA	SOS	SGCI	SCI	CSI	ST	OSC	PM	APC
A...	NBSP	Ą	Ć	Ł	Ś	Ş	Š	Ÿ	Ž	Š	Ş	Ž	Š	ŠY	Ž	Ž
B...	°	ą	ć	ł	ś	ş	š	ž	š	ş	ž	š	š	š	ž	ž
C...	Ř	Á	Â	Ã	Ä	Å	Ĺ	Č	Ç	Č	É	Ę	Ê	Ë	Í	Î
D...	Đ	Ñ	Ń	Ó	Ô	Õ	Ö	×	Ř	Ú	Ú	Ů	Ů	Ý	Ť	ß
E...	í	á	â	ă	ä	å	í	ć	ç	č	é	ę	ê	ë	í	î
F...	đ	ñ	ń	ó	ô	õ	ö	÷	ř	ú	ú	ů	ů	ý	ť	·

ISO-8859-15

Modifizierte ISO-8859-1 mit €

Code	...0	...1	...2	...3	...4	...5	...6	...7	...8	...9	...A	...B	...C	...D	...E	...F
0...	NUL	SOH	STX	ETX	EOT	ENQ	ACK	BEL	BS	HT	LF	VT	FF	CR	SO	SI
1...	DLE	DC1	DC2	DC3	DC4	NAK	SYN	ETB	CAN	EM	SUB	ESC	FS	GS	RS	US
2...	SP	!	"	#	\$	%	&	'	()	*	+	,	-	.	/
3...	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4...	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5...	P	Q	R	S	T	U	V	W	X	Y	Z	[\]	^	_
6...	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7...	p	q	r	s	t	u	v	w	x	y	z	{		}	~	DEL
8...	PAD	HOP	BPH	NBH	IND	NEL	SSA	ESA	HTS	HTJ	VTS	PLD	PLU	RI	SS2	SS3
9...	DCS	PU1	PU2	STS	CCH	MW	SPA	EPA	SOS	SGCI	SCI	CSI	ST	OSC	PM	APC
A...	NBSP	ı	ċ	£	€	¥	Š	š	š	©	ª	«	¬	SHY	®	-
B...	°	±	²	³	Ž	μ	¶	·	ž	¹	º	»	Œ	œ	Ÿ	ı
C...	À	Á	Â	Ã	Ä	Å	Æ	Ç	È	É	Ê	Ë	Ì	Í	Î	Ï
D...	Ð	Ñ	Ò	Ó	Ô	Õ	Ö	×	Ø	Ù	Ú	Û	Ü	Ý	Þ	ß
E...	à	á	â	ã	ä	å	æ	ç	è	é	ê	ë	ì	í	î	ï
F...	ð	ñ	ò	ó	ô	õ	ö	÷	ø	ù	ú	û	ü	ý	þ	ÿ

Microsoft: Codepage 437, 850, 1252

- ▶ Zeichensatz des IBM-PC ab 1981
- ▶ Erweiterung von ASCII auf einen 8-bit Code
- ▶ einige Umlaute (westeuropäisch)
- ▶ Graphiksymbole

- ▶ http://de.wikipedia.org/wiki/Codepage_437
- ▶ verbesserte Version: Codepage 850, 858 (€-Symbol an 0xD5)
- ▶ Codepage 1252 entspricht (weitgehend) ISO-8859-1
- ▶ Sonderzeichen liegen an anderen Positionen als bei ISO-8859

Windows: Codepage 850

	*0	*1	*2	*3	*4	*5	*6	*7	*8	*9	*A	*B	*C	*D	*E	*F
0*		☺	☹	♥	♦	♣	♠	•	◻	◯	◼	♂	♀	♪	♫	☼
1*	▶	◀	↕	!!	¶	§	—	↕	↑	↓	→	←	↔	▲	▼	
2*		!	"	#	\$	%	&	'	()	*	+	,	-	.	/
3*	0	1	2	3	4	5	6	7	8	9	:	;	<	=	>	?
4*	@	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
5*	P	Q	R	S	T	U	V	W	X	Y	Z	[\]	^	_
6*	`	a	b	c	d	e	f	g	h	i	j	k	l	m	n	o
7*	p	q	r	s	t	u	v	w	x	y	z	{		}	~	△
8*	Ç	ü	é	â	ã	à	â	ç	ê	ë	è	ï	î	ì	Ä	Å
9*	É	æ	Æ	ô	ö	ò	û	ù	ÿ	Ö	Ü	ø	£	Ø	×	f
A*	á	í	ó	ú	ñ	Ñ	ª	º	¿	®	¬	½	¼	¡	«	»
B*	⌘	⌘	⌘			Á	Â	À	©	¶	¶	¶	¶	¢	¥	₯
C*	Ł	ł	Ł	ł	—	—	—	—	—	—	—	—	—	—	—	—
D*	ð	Ð	Ê	Ë	È	É	Í	Î	Ĭ	Ĵ	Ĵ	■	■	ı	ı	■
E*	Ó	β	Ô	Ò	õ	Õ	μ	ρ	ρ	Ú	Ú	Ù	ý	Ý	-	'
F*		±	=	¾	¶	§	÷	,	°	°	°	1	3	2	■	

Austausch von Texten?

- ▶ die meisten gängigen Codes (abwärts-) kompatibel mit ASCII
- ▶ unterschiedliche Kodierung für Umlaute (soweit vorhanden)
- ▶ unterschiedliche Kodierung der Sonderzeichen

- ▶ Unterschiedliche Konvention für Zeilenende
 - ▶ DOS/Windows: CR/LF (0D 0A)
 - ▶ Unix/Linux: LF
 - ▶ Mac OS 9: CR

 - ▶ Konverter-Tools: dos2unix, unix2dos, iconv

Unicode: Motivation

- ▶ zunehmende Vernetzung und Globalisierung
- ▶ internationaler Datenaustausch?
- ▶ Erstellung mehrsprachiger Dokumente?
- ▶ Unterstützung orientalischer oder asiatischer Sprachen?

- ▶ ASCII oder ISO-8859-1 reicht nicht aus
- ▶ temporäre Lösungen konnten sich nicht durchsetzen, z.B:
ISO-2022: Umschaltung zwischen mehreren Zeichensätzen durch Spezialbefehle (*Escapesequenzen*).

- ⇒ **Unicode** als System zur Kodierung aller Zeichen aller bekannten (lebenden oder toten) Schriftsysteme

Unicode: Versionen und History

- ▶ auch abgekürzt als UCS: **Universal Character Set**
- ▶ zunehmende Verbreitung (Betriebssysteme, Applikationen)
- ▶ Darstellung erfordert auch entsprechende Schriftarten
- ▶ <http://www.unicode.org>
<http://www.unicode.org/charts>
- ▶ 1991 1.0.0: europäisch, nahöstlich, indisch
- ▶ 1992 1.0.1: ostasiatisch (Han)
- ▶ 1993 akzeptiert als ISO/IEC-10646 Standard
- ▶ ...
- ▶ 2010 6.0: knapp 110.000 Zeichen enthalten

<http://www.unicode.org>, <http://de.wikipedia.org/wiki/Unicode>

Unicode: Schreibweise

- ▶ ursprüngliche Version nutzt 16-bit pro Zeichen
- ▶ die sogenannte „*Basic Multilingual Plane*“
- ▶ Schreibweise hexadezimal als U+xxxx
- ▶ Bereich von U+0000 .. U+FFFF
- ▶ Schreibweise in Java-Strings: \uxxxx
z.B. \u03A9 für Ω, \u20AC für das €-Symbol
- ▶ mittlerweile mehr als 2¹⁶ Zeichen
- ▶ Erweiterung um „*Extended Planes*“
- ▶ U+10000 .. U+10FFFF

Unicode: in Webseiten (HTML)

- ▶ HTML-Header informiert über verwendeten Zeichensatz
- ▶ Unterstützung und Darstellung abhängig vom Browser
- ▶ Demo <http://www.columbia.edu/~fdc/utf8>

```
<html>
<head>
<META http-equiv="Content-Type"
      content="text/html; charset=utf-8">
<title>UTF-8 Sampler</title>
</head>
...
```


Unicode: Demo

<http://www.columbia.edu/~fdc/utf8>

1. **English:** The quick brown fox jumps over the lazy dog.
2. **Jamaican:** Chruu, a kwik di kwik brong fox a jomp huova di liezi daag de, yu no siit?
3. **Irish:** "An bfuil do croí ag bualadh ó faitíos an grá a mheall lena póg éada ó slí do leasa tú?" "D'fhuascail íosa Úrmac na hÓige Beannaithe pór Éava agus Ádairín."
4. **Dutch:** Pa's wijze lynx bezag vroom het fikse aquaduct.
5. **German:** Falsches Üben von Xylophonmusik quält jeden größeren Zwerg. (1)
6. **German:** Im finsternen Jagdchloß am offenen Felsquellwalfer patzte der affig-flatterhafte kauzig-höfliche Bäcker über feinem veriffiten kniffiligen C-Xylophon. (2)
7. **Norwegian:** Blåbærsyltetøy ("blueberry jam", includes every extra letter used in Norwegian).
8. **Swedish:** Flygande bäckasiner söka strax hwila på mjuka tuvor.
9. **Icelandic:** Sævor grét áðan því úlpan var ónýt.
10. **Finnish:** (5) Törkylempijävongahdus (This is a perfect pangram, every letter appears only once. Translating it is an art on its own, but I'll say "rude lover's yelp". :D)
11. **Finnish:** (5) Albert osti fagotin ja töräytti puhkuvan melodian. (Albert bought a bassoon and hooted an impressive melody.)
12. **Finnish:** On sangen hauskaa, että polkupyörä on maanteiden jokapäiväinen ilmiö. (It's pleasantly amusing, that the bicycle is an everyday sight on the roads.)
13. **Polish:** Pchnąć w tę łódź jeża lub ośiem skrzyń fig.
14. **Czech:** Příliš žluťoučký kůň úpěl ďábelské kódy.
15. **Slovak:** Starý kôň na hrbie knih žuje tiško povádnuté ruže, na sfípe sa ďateľ učí kvákať novú ódu o živote.
16. **Greek (monotonic):** ξεσκεπάσω την ψυχοφθόρα βδελυγμία
17. **Greek (polytonic):** ξεσκεπάσω τήν ψυχοφθόρα βδελυγμία
18. **Russian:** Съешь же ещё этих мягких французских булок да выпей чаю.
19. **Russian:** В чашках юга жип-был цитрус? Да, но фальшивый экземпляр! ёъ.
20. **Bulgarian:** Жълтата дюля беше щастлива, че пухът, който цъфна, замръзна като гьон.
21. **Sami (Northern):** Vuol Ruota gedggiid leat mánga luosa ja čuoŋžža.
22. **Hungarian:** Árvízűről tükörfűrőgép.
23. **Spanish:** El pingüino Wenceslao hizo kilómetros bajo exhaustiva lluvia y frío, añoraba a su querido cachorro.
24. **Portuguese:** O próximo vôo à noite sobre o Atlântico, põe frequentemente o único médico. (3)
25. **French:** Les naïfs ægithales hâtifs pondant à Noël où il gèle sont sûrs d'être déçus en voyant leurs drôles d'œufs abîmés.
26. **Esperanto:** Eĥoŝanĝo ĉiujŝade.
27. **Hebrew:** זה כיף סתם לשמוע איך תנצח קרפד עץ טוב בגן.
28. **Japanese (Hiragana):**

いろはにほへど ちりぬるを
わがよたれぞ つねならむ
うぬのおくやま けふこえて
あさきゆめみじ ゑひもせず (4)

Unicode: Demo (cont.)

<http://www.columbia.edu/~fdc/utf8>

[Šota Rustaveli](#)'s Vepxis Tq̄aosani, ოჲ, *The Knight in the Tiger's Skin* (Georgian):

ვეპხის ტყაოსანი შოთა რუსთაველი

ღმერთის შემდეგდრე, ნუთუ კვლა დამხსნას სოფლისა შრომასა, ცეცხლს, წყალსა და მიწასა,
ჰაერთა თანა მრომასა; მომცნეს ფრთენი და აღფურინდე, მივჰხუდე მას ჩემსა ნდომასა, დღისით
და ღამით ვჰხედვიდე მზისა ელვათა კრთომასა.

Tamil poetry of Subramaniya Bharathiyar: சுப்ரமணிய பாரதியார் (1882-1921):

யாமறிந்த மொழிகளிலே தமிழ்மொழி போல் இனிதாவது எங்கும் காணோம்,
பாமரராய் விலங்குகளாய், உலகனைத்தும் இகழ்ச்சிசொலப் பான்மை கெட்டு,
நாமமது தமிழ்ரெனக் கொண்டு இங்கு வாழ்ந்திடுதல் நன்றோ? சொல்லீர்!
தேமதுரத் தமிழோசை உலகமெலாம் பரவும்வகை செய்தல் வேண்டும்.

Unicode: Latin-Zeichen

- ▶ Zeichen im Bereich U+0000 bis U+007F wie ASCII
www.unicode.org/charts/PDF/U0000.pdf
- ▶ Bereich von U+0100 bis U+017F für Latin-A
Europäische Umlaute und Sonderzeichen
www.unicode.org/charts/PDF/U0100.pdf
- ▶ viele weitere Sonderzeichen ab U+0180
Latin-B, Latin-C, usw.

Unicode: Mathematische Symbole und Operatoren

Vielfältige Auswahl von Symbolen und Operatoren

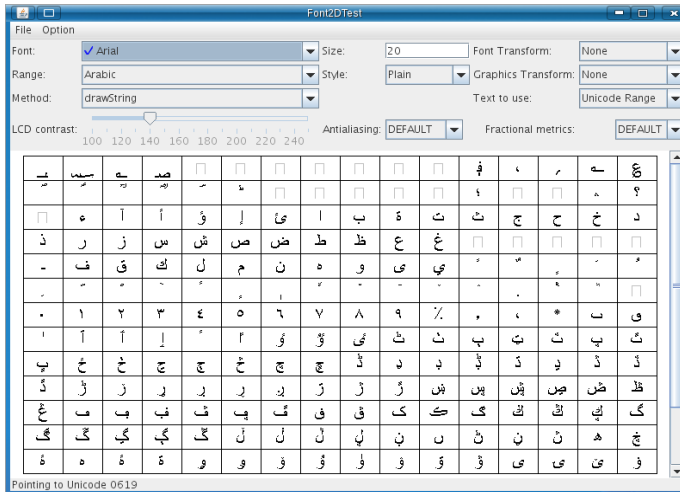
- ▶ griechisch www.unicode.org/charts/PDF/U0370.pdf
- ▶ letterlike Symbols www.unicode.org/charts/PDF/U2100.pdf
- ▶ Pfeile www.unicode.org/charts/PDF/U2190.pdf
- ▶ Operatoren www.unicode.org/charts/PDF/U2A00.pdf
- ▶ ...
- ▶ Dingbats www.unicode.org/charts/PDF/U2700.pdf

Unicode: Asiatische Sprachen

Chinesisch (traditional/simplified), Japanisch, Koreanisch

- ▶ U+3400 bis U+4BDF
www.unicode.org/charts/PDF/U3400.pdf
- ▶ U+4E00 bis U+9FCF
www.unicode.org/charts/PDF/U4E00.pdf

Unicode: Java2D Fontviewer



Oracle
Java JDK examples
../demo/jfc/Font2DTest

Unicode: Repräsentation?

- ▶ 16-bit für jedes Zeichen, bis zu 65536 Zeichen
- ▶ schneller Zugriff auf einzelne Zeichen über Arrayzugriffe (Index)
- ▶ aber: doppelter Speicherbedarf gegenüber ASCII/ISO-8859-1
- ▶ Verwendung u.a. in Java: Datentyp `char`

- ▶ ab Unicode-3: mehrere *Planes* zu je 65536 Zeichen
- ▶ direkte Repräsentation aller Zeichen erfordert 32-bit/Zeichen
- ▶ vierfacher Speicherbedarf gegenüber ISO-8859-1

- ▶ bei Dateien ist möglichst kleine Dateigröße wichtig
- ▶ effizientere Kodierung üblich: UTF-16 und UTF-8

UTF-8

Zeichen	Unicode	Unicode binär	UTF-8 binär	UTF-8 hexadezimal
Buchstabe y	U+0079	00000000 01111001	01111001	0x79
Buchstabe ä	U+00E4	00000000 11100100	11000011 10100100	0xC3 0xA4
Zeichen für eingetragene Marke ®	U+00AE	00000000 10101110	11000010 10101110	0xC2 0xAE
Eurozeichen €	U+20AC	00100000 10101100	11100010 10000010 10101100	0xE2 0x82 0xAC
Violschlüssel	U+1D11E	00000001 11010001 00011110	11110000 10011101 10000100 10011110	0xF0 0x9D 0x84 0x9E

<http://de.wikipedia.org/wiki/UTF-8>

- ▶ effiziente Kodierung von „westlichen“ Unicode-Texten
- ▶ Zeichen werden mit variabler Länge kodiert, 1..4-Bytes
- ▶ volle Kompatibilität mit ASCII

UTF-8: Algorithmus

Unicode-Bereich (hexadezimal)	UTF-Kodierung (binär)	Anzahl (benutzt)
0000 0000 - 0000 007F	0*** **	128
0000 0080 - 0000 07FF	110* **** 10** ****	1920
0000 0800 - 0000 FFFF	1110 **** 10** **** 10** ****	63488
0001 0000 - 0010 FFFF	1111 0*** 10** **** 10** **** 10** ****	bis 2^{21}

- ▶ untere 128 Zeichen kompatibel mit ASCII
- ▶ Sonderzeichen westlicher Sprachen je zwei Bytes
- ▶ führende Eins markiert Multi-Byte Zeichen
- ▶ Anzahl der führenden Einsen gibt Anz. Bytegruppen an
- ▶ Zeichen ergibt sich als Bitstring aus den ***...*
- ▶ theoretisch bis zu sieben Folgebytes a 6-bit: max. 2^{42} Zeichen

Sprach-Einstellungen: Locale

Locale: die Sprach-Einstellungen und Parameter

- ▶ auch: `i18n` („internationalization“)
- ▶ Sprache der Benutzeroberfläche
- ▶ Tastaturlayout/-belegung
- ▶ Zahlen-, Währungs-, Datums-, Zeitformate
- ▶ Linux/POSIX: Einstellung über die Locale-Funktionen der Standard C-Library (Befehl `locale`)
- Java: `java.util.Locale`
- Windows: Einstellung über System/Registry-Schlüssel

dos2unix, unix2dos

- Umwandeln von ASCII-Texten (z.B. Programm-Quelltexte) zwischen DOS/Windows und Unix/Linux Maschinen

- Umwandeln von a.txt in Ausgabedatei b.txt:

```
dos2unix -c ascii -n a.txt b.txt
```

```
dos2unix -c iso -n a.txt b.txt
```

```
dos2unix -c mac -n a.txt b.txt
```

- Umwandeln von Unix nach DOS/Windows, Codepage 850:

```
unix2dos -850 -n a.txt b.txt
```

iconv

Das Schweizer-Messer zur Umwandlung von Textkodierungen.

► Optionen

- `-f, --from-code=<encoding>` Kodierung der Eingabedatei
- `-t, --to-code=<encoding>` Kodierung der Ausgabedatei
- `-l, --list` Liste der unterstützten Kodierungen ausgeben
- `-o, --output=<filename>` Name der Ausgabedatei

► Beispiel

```
iconv -f=iso-8859-1 -t=utf-8 -o foo.utf8.txt foo.txt
```

base64-Kodierung

Übertragung von (Binär-) Dateien zwischen verschiedenen Rechnern?

- ▶ SMTP (Internet Mail-Protokoll) verwendet 7-bit ASCII
- ▶ bei Netzwerk-Übertragung müssen alle Rechner/Router den verwendeten Zeichensatz unterstützen
- ⇒ Verfahren zur Umkodierung der Datei in 7-bit ASCII notwendig
- ⇒ etabliert ist das **base-64** Verfahren (RFC 2045)
- ▶ alle e-mail Dateianhänge und 8-bit Textdateien
- ▶ Umkodierung benutzt nur Buchstaben, Ziffern und drei Sonderzeichen

base64-Kodierung: Prinzip

- Kodierung von drei 8-bit Bytes als vier 6-bit Zeichen
- erfordert 64 der verfügbaren 128 7-bit ASCII Symbole

► Codierung

A..Z Codes: 0..25


a..z Codes: 26..51

0..9 Codes: 52..61

+ Code: 62

/ Code: 63

= Füllzeichen, falls Anzahl der Bytes nicht durch 3 teilbar
CR Zeilenumbruch (optional), meistens nach 76 Zeichen



base64-Kodierung: Prinzip (cont.)

Text content	M								a								n							
ASCII	77								97								110							
Bit pattern	0	1	0	0	1	1	0	1	0	1	1	0	0	0	0	1	0	1	1	0	1	1	1	0
Index	19								22								5							
Base64-encoded	T								W								F							

- ▶ drei 8-bit Zeichen, re-gruppert als vier 6-bit Blöcke
- ▶ Zuordnung des jeweiligen Buchstabens/Ziffer
- ▶ ggf. =, == am Ende zum Auffüllen
- ▶ Übertragung dieser Zeichenfolge ist 7-bit kompatibel
- ▶ resultierende Datei ca. 33% größer als das Original

base64-Kodierung: Tools

- ▶ im Java JDK enthalten
aber im inoffiziellen internen Teil
`sun.misc.BASE64Encoder`, bzw. `sun.misc.BASE64Decoder`
- ▶ aber diverse (open-source) Implementierungen verfügbar
Beispiel: Apache Commons <http://commons.apache.org/codec>
`org.apache.commons.codec.binary.Base64`
`org.apache.commons.codec.binary.Base64InputStream`
`org.apache.commons.codec.binary.Base64OutputStream`

base64-Kodierung: Beispiel

openbook.galileodesign.de/javainsel7/javainsel_04_008.htm

```
import java.io.IOException;
import java.util.*;
import sun.misc.*;

public class Base64Demo
{
    public static void main( String[] args ) throws IOException
    {
        byte[] bytes1 = new byte[ 112 ];
        new Random().nextBytes( bytes1 );

        // buf in String
        String s = new BASE64Encoder().encode( bytes1 );
        System.out.println( s );

        // Zum Beispiel:
        // QFgwDyiQ28/4GsF75fqLMj/bAIWNw0uBmE/SCl3H2XQFpSsSz0jtyR0LU+kLiWwsnSUZljJr97Hy
        // LA3YUbf96Ym2zx9F9Y1N7P5lsOCb/vr2crTQ/gXs757qaJF9E3szMN+E0CSSslDrrzcNBr1cQg==
        // String in byte[]
        byte[] bytes2 = new BASE64Decoder().decodeBuffer( s );
        System.out.println( Arrays.equals(bytes1, bytes2) );    // true
    }
}
```

Literatur: Vertiefung

- ▶ <http://www.unicode.org>
- ▶ The Java Tutorials, *Trail: Internationalization*
<http://download.oracle.com/javase/tutorial/i18n>